IL MODELLO RELAZIONALE

Cos’è un modello dati?

- In generale, è un insieme di **concetti formali** utilizzati per descrivere la struttura delle informazioni di interesse, le relazioni tra di esse e i vincoli che devono rispettare
- Offre un'**astrazione del mondo reale** che consente di organizzare i dati in modo coerente, eliminando i dettagli di basso livello relativi alla memorizzazione fisica su disco (file system, settori, memoria, …)

Cos'è un modello dati?

Un modello dati è definito da:

- **Strutture dati** (es. relazioni, alberi, grafi, …)
- **Operatori** per manipolare e interrogare i dati basandosi sulle strutture definite (es. selezione, proiezione, join, attraversamento di nodi, gerarchie di classi, …)
- **Vincoli** che garantiscano la correttezza dei dati nel tempo (es. chiavi primarie, integrità referenziale, unicità di valori, …)

Il modello relazionale: concetti generali

- Il modello fu proposto da E.F. Codd (IBM Research) nel 1970 in un famosissimo articolo:
  - "A Relational Model for Large Shared Data Banks," Communications of the ACM, June 1970
- Il modello si basa sul concetto matematico di relazione, basato sulla teoria degli insiemi
- Questo lavoro fu alla base di una profonda rivoluzione nel campo delle basi di dati, che portò Codd a vincere il prestigioso ACM Turing Award

Cos'è una relazione?

Formalmente, una **relazione** è definita come segue:

- Un **dominio** *D* è un insieme di valori omogenei (es. stringhe, numeri interi, booleani, …)
- Dati *n* domini D_1, D_2, …, D_n (non necessariamente distinti), il loro **prodotto cartesiano** $D_1 \times D_2 \times \ldots D_n$ è l'insieme di tutte le tuple ordinate $(v_1, v_2, \ldots, v_n)$ tali che $v_i \in D_i$ per ogni $i \in \{v_1, \ldots, vn\}$
- Una **relazione** *R* sui domini $D_1 \times D_2 \times \ldots D_n$ è definita come un sottoinsieme del loro prodotto cartesiano:

$$R \subseteq D_1 \times D_2 \times \cdots \times D_n$$

Stato di una relazione

Lo **stato di una relazione** è uno specifico sottoinsieme del prodotto cartesiano dei domini dei suoi attributi.

- Data una relazione $R(A_1, A_2, ..., A_n)$, uno stato *s* di R è definito come segue:

$$s(R) \subset \text{dom}(A_1) \text{ X } \text{dom}(A_2) \text{ X } ....\text{X } \text{dom}(A_n)$$

- ovvero:
  - $s(R) = \{t_1, t_2, \ldots, t_n\}$ dove ogni t_i è una tupla
  - $t_i = <v_1, v_2, \ldots, v_n>$ dove ogni v_j è un elemento di $\text{dom}(A_j)$

- Nello stato di una relazione, l'ordine delle tuple non conta (è un insieme!)

Esempio

- Sia $R(A_1, A_2)$ lo schema di una relazione con:
  - $dom(A_1) = \{0,1\}$
  - $dom(A_2) = \{a,b,c\}$
- $dom(A_1)$ X $dom(A_2)$ è l'insieme di tutte le possibili coppie ordinate dei valori di A_1 e A_2 :

  {<0,a> , <0,b> , <0,c>, <1,a>, <1,b>, <1,c> }

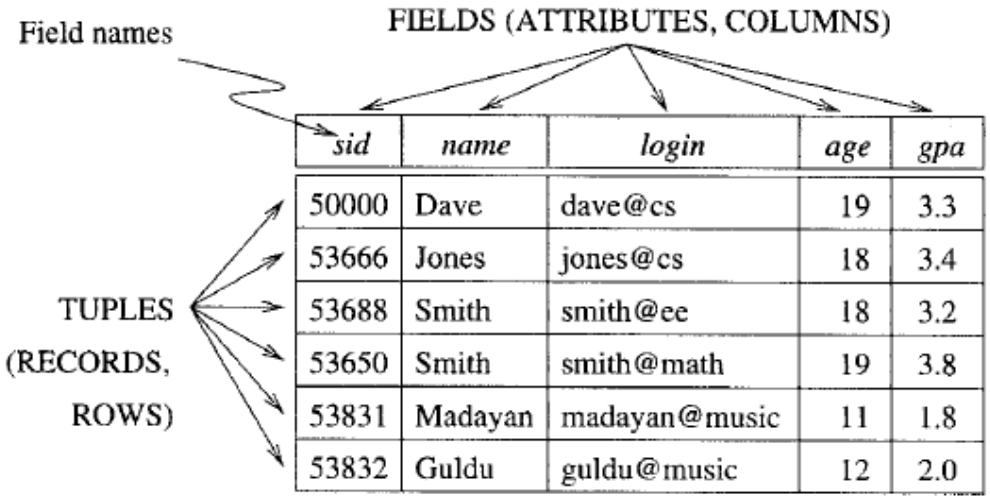
- Un possibile stato *s*(R) è dato dall'insieme di tuple

  {<0,a> , <0,b> , <1,c> }

- Si dice che questo è un possibile stato (o «popolazione» o «estensione») *s* della relazione R definita su A_1 and A_2
- Questo stato ha **cardinalità** 3 (ci sono 3 tuple)

Cos'è una relazione?

- *Informalmente*, una **relazione** può essere vista come una **tabella** le cui colonne (**attributi**) corrispondono ai domini e ogni **riga** (o **record** o **tupla**) è un insieme di valori ordinati.
- Ci sono due livelli che definiscono una relazione:
  - Lo **schema** della relazione (livello *intensionale*)
  - **Istanze** della relazione (livello *estensionale*)



sid	*name*	*login*	*age*	*gpa*
50000	Dave	dave@cs	19	3.3
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@ee	18	3.2
53650	Smith	smith@math	19	3.8
53831	Madayan	madayan@music	11	1.8
53832	Guldu	guldu@music	12	2.0

Relazioni: definizione intensionale

- Lo schema di una relazione definisce:
  - Il nome della relazione (per esempio, STUDENTI)
  - Il nome di ogni attributo (per esempio, SID, NOME, LOGIN, …)
  - Il dominio di ogni attributo (per esempio, INTEGER, STRING, …), ovvero l'insieme dei valori che quell'attributo può assumere
- L'ordine degli attributi nello schema non ha alcun significato specifico

Relazioni: definizione intensionale

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

- Un modo standard di rappresentare lo schema di una relazione è il seguente:

  Students(*sid*:`string`, *name*:`string`, *login*:`string`, *age*:`integer`, *gpa*:`real`)

- Il numero di attributi definisce il **grado** (o *arietà*) **della relazione** (5 nell'esempio sopra)

Relazioni: definizione estensionale

- Un'istanza di uno schema di relazione è un **insieme** di **tuple** (**record**), ognuna delle quali ha lo stesso numero di campi dello schema della relazione
  - Essendo un insieme, non possono esserci duplicati!
  - L'ordine delle tuple non ha alcun valore specifico

- *Informalmente,* un'istanza di una relazione può essere pensata come un insieme di righe di una tabella, dove ovviamente tutte le righe hanno lo stesso numero di campi
  - *Formalmente*, un'istanza coincide con il concetto di stato di una relazione R

- Il numero di istanze della definisce la **cardinalità** della relazione (3 nell'esempio sulla slide precedente)

Chiave di una relazione

- Ogni riga di una relazione ha un campo (o un insieme di campi) il cui valore (o i cui valori) identificano unicamente quella riga in quella tabella
  - Si parla di **chiave** (*key*) della relazione
    - Nella relazione STUDENTS, l'attributo SSN ha valori che non possono ripetersi mai uguali in due righe diverse e quindi identifica univocamente uno studente
- Talvolta si usano valori convenzionali per identificare una riga in una tabella
  - Si parla di *chiavi artificiali* (*artificial key)* o *chiavi surrogate* (*surrogate key)*

Terminologia

Informale	Formale
Tabella	Relazione
Intestazione colonna	Attributo
Tutti i possibili valori di una colonna	Dominio
Riga della tabella	Tupla
Definizione della tabella	Schema della relazione
Tabella popolata	Stato della Relazione

VINCOLI

I vincoli determinano quali stati di una relazione in una base di dati relazionale sono ammissibili e quali non lo sono

I principali vincoli sono di tre tipi:

1. **Vincoli impliciti**: dipendono dal *data model* stesso (per es. il modello relazionale non ammette liste come valore di alcun attributo)
2. **Vincoli basati sullo schema** (o **espliciti**): sono definiti nello schema usando gli strumenti forniti dal modello (per es. un vincolo di integrità referenziale)
3. **Vincoli applicativi** o **semantici**: si tratta di vincoli che vanno al di là del potere espressivo del modello e devono essere imposti a livello di programma applicativo (per es. che un libro deve essere restituito alla biblioteca entro 30 giorni dal prestito)

Vincoli di integrità relazionale

- Un vincolo è definito come una **condizione** che DEVE valere affinché lo **stato** di una relazione sia **valido**

- I principali tipi di vincoli espliciti che possono essere espressi nel modello relazionale sono:
  - Vincolo di **dominio** (già discusso)
  - Vincolo di **chiave**
  - Vincolo di **integrità** delle entità
  - Vincolo di **integrità referenziale**

Vincolo di chiave - Definizioni

- **Superchiave** di una relazione R:
  - È un insieme di attributi S_K di R tali che:
    - Non esistono due tuple di r(R) in cui gli attributi in S_K hanno lo stesso valore (ovvero, se t_1 e t_2 sono tuple distinte di r(R), $t_1[S_K] \neq t_2[S_K]$
    - Questa condizione deve essere rispettata in *ogni stato valido di* R
- **Superchiavi minimali** e **chiavi candidate** di una relazione R:
  - Una superchiave si dice **minimale** quando la rimozione di qualsiasi attributo da S_K produce un insieme di attributi che non è più una superchiave di R
  - Una superchiave minimale è detta anche una **chiave candidata**
- **Una chiave (candidata) è sempre una superchiave, ma non viceversa**

Esempio

- Consideriamo la relazione STUDENT qui sotto:
  - STUDENT ha due *chiavi candidate*:
    - Chiave 1 = {sid}
    - Chiave 2 = {login}
  - Entrambe sono chiavi (e quindi superchiavi) di STUDENT
  - {sid, name} è una superchiave ma *non* una chiave (perché?)
  - Ogni insieme di attributi che contiene una chiave candidata è ovviamente una superchiave

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

Vincolo di chiave

- Se una relazione ha più di una **chiave candidata**, una viene scelta (tipicamente dal DBA) come **chiave primaria**.
  - In generale, viene scelta la chiave candidata più piccola (come numero di attributi che la compongono)
  - Quando non è possibile, possono intervenire fattori soggettivi o addirittura arbitrari
- I valori della chiave primaria sono usati per *identificare in modo univoco* ogni tupla della relazione
  - In un certo senso forniscono l'«identità» della tupla
- Come vedremo, può essere usata per fare riferimento a quella tupla da tuple di un'altra relazione

Vincolo di integrità di un'Entità (*entity integrity*)

- Nessuno degli attributi che compongono la chiave primaria P_K di una relazione R può avere valore NULL in alcuna tupla di r(R)
  - $t[P_K] \neq$ null per ogni tupla t in r(R)
  - Se P_K ha più di un attributo, il valore NULL non è ammesso per nessuno degli attributi che la compongono
- Nota bene: è possibile imporre che anche altri attributi non possano assumere il valore NULL, anche se non sono (parte della) chiave primaria.

Vincoli di integrità referenziale

- A differenza degli altri vincoli, un vincolo di integrità referenziale coinvolge due relazioni:
  - una **relazione referenziante** R_1
  - una **relazione referenziata** R_2
- In R1 c'è un insieme di attributi FK (chiamati **chiave esterna** / *Foreign Key*) che fanno riferimento agli attributi della chiave primaria PK (*Primary Key*) di R_2
- Una tupla t_1 in R_1 si dice che **referenzia** una tupla t_2 in R_2 se $t_1[FK] = t_2[PK]$

Vincoli di integrità referenziale: esempio

- Enrolled è la **relazione referenziante**
- Students è la **relazione referenziata**
- `Enrolled.sid` è la **chiave esterna** che fa riferimento alla **chiave primaria** di Students (`Students.sid`)
  - La prima, la seconda e la quarta tupla di Enrolled **referenziano** la prima di Students

Enrolled

sid	cid	grade
53666	Carnatic101	C
53666	Reggae203	B
53650	Topology112	A
53666	History105	B

Students

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

Vincoli di integrità referenziale

- I valori degli attributi della chiave esterna FK della **relazione referenziante** R1 possono essere:
  1. Uno dei valori del corrispondente attributo della chiave primaria PK in R2, oppure
  2. Assumere il valore NULL

- Se NULL, ovviamente la FK in R_1 non deve far parte degli attributi della propria chiave primaria!

Vincoli di integrità referenziale

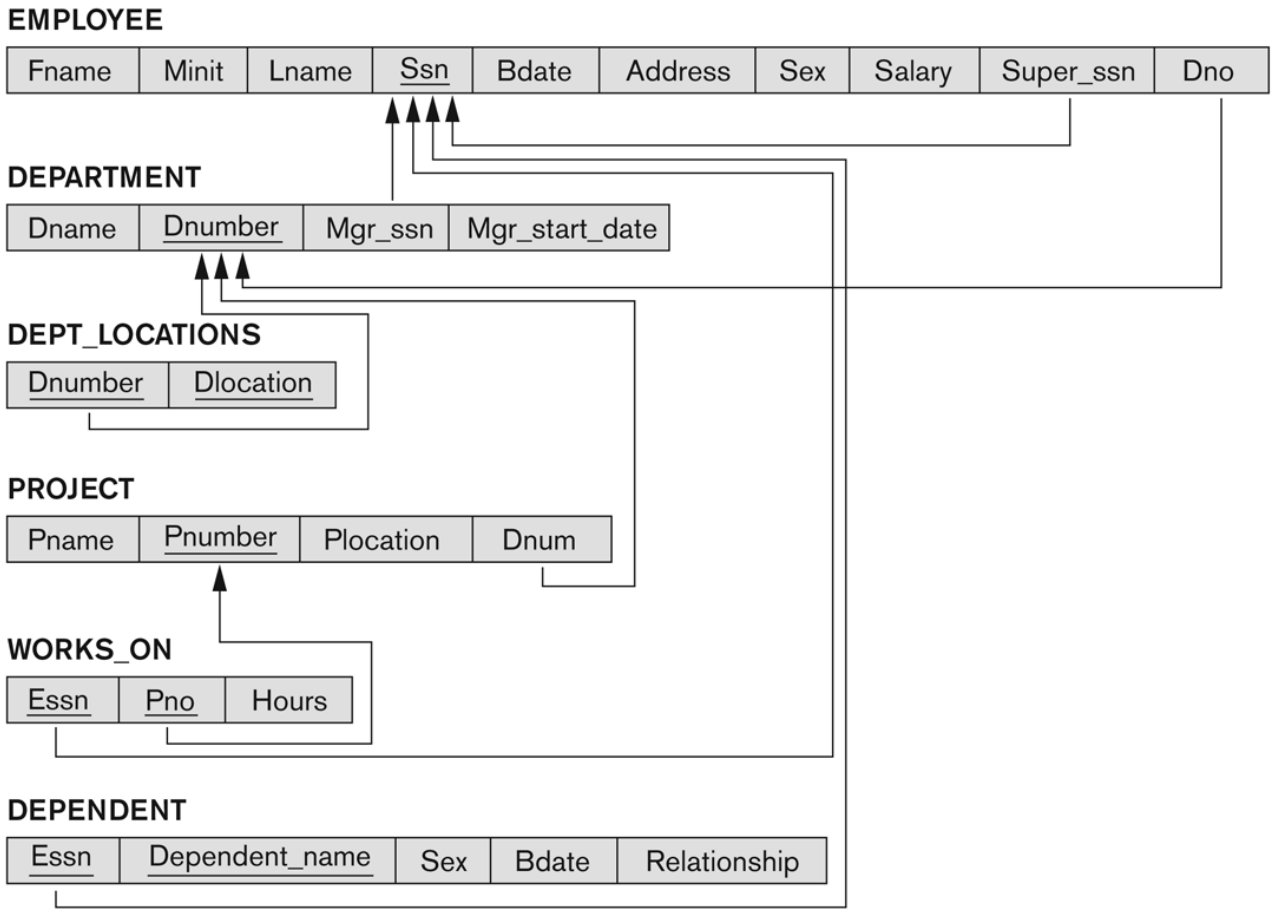
- **Osservazione 1**: la FK può fare riferimento alla stessa relazione di appartenenza della PK!
- **Osservazione 2**: gli attributi appartenenti alla FK non necessariamente hanno lo stesso nome dei corrispondenti attributi appartenenti alla PK

EMPLOYEE

Fname	Minit	Lname	Ssn	Bdate	Address	Sex	Salary	Super_ssn	Dno
John	B	Smith	123456789	1965-01-09	731 Fondren, Houston, TX	M	30000	333445555	5
Franklin	T	Wong	333445555	1955-12-08	638 Voss, Houston, TX	M	40000	888665555	5
Alicia	J	Zelaya	999887777	1968-01-19	3321 Castle, Spring, TX	F	25000	987654321	4
Jennifer	S	Wallace	987654321	1941-06-20	291 Berry, Bellaire, TX	F	43000	888665555	4
Ramesh	K	Narayan	666884444	1962-09-15	975 Fire Oak, Humble, TX	M	38000	333445555	5
Joyce	A	English	453453453	1972-07-31	5631 Rice, Houston, TX	F	25000	333445555	5
Ahmad	V	Jabbar	987987987	1969-03-29	980 Dallas, Houston, TX	M	25000	987654321	4
James	E	Borg	888665555	1937-11-10	450 Stone, Houston, TX	M	55000	NULL	1

Referential Integrity Constraints for COMPANY database

Figure 5.7
Referential integrity constraints displayed on the COMPANY relational database schema.



Schema di un database relazionale

- A differenza degli altri vincoli, i vincoli di integrità referenziale coinvolgono più di una relazione, per cui non basta considerare lo schema di una singola relazione
- Uno **schema di un database relazionale** è un insieme S di schemi di relazione che appartengono alla stessa base di dati
  - S = <{R_1, R_2, ..., R_n}, IC> dove:
    - R_1, R_2, …, R_n sono i nomi dei singoli schemi di relazione che appartengono alla base di dati S
    - IC è un insieme di vincoli di integrità

Altri tipi di vincolo

- Vincoli di Integrità Semantica:
  - Sono riferiti al significato dell'applicazione e non possono essere espressi nel modello in sé
  - Esempio: "Il numero massimo di ore che un dipendente può lavorare su tutti i progetti è di 46 ore per settimana"
- Diventa necessario un linguaggio per la **specifica di vincoli**
  - SQL-99 introduce i concetti di «trigger» e «asserzioni» per definire condizioni, ma non tutti i DBMS li implementano e spesso in modi diversi. In MYSQL si può usare il comando CHECK per esprimere vincoli sui valori degli attributi
  - Esempio:

```
CREATE TABLE Person (...,
Age int CHECK (Age>=18) );
```

Stato di una base di dati relazionale

- Ogni *relazione* è tipicamente popolata da un certo numero di tuple (*stato della relazione*)
- Uno **stato di una base di dati relazionale** con schema *S* è un insieme di stati delle relazioni {r_1, r_2, ..., r_m} tali che ogni r_i è uno stato di R_i e tale che r_i soddisfa i vincoli di integrità relazionale in IC.
  - Uno **stato di una base di dati relazionale** viene talvolta chiamato un'*istantanea* (*snapshot*) o *istanza* (*instance*) della base di dati
- Uno stato di base di dati che non rispetta i vincoli in IC è uno **stato non valido**

Stato di una base di dati popolata

- Lo *stato della base di dati è* l'unione di tutti i singoli stati delle relazioni che compongono la base di dati
- Ogni volta che la base di dati è modificata, si passa in un nuovo stato della base di dati
- Le principali operazioni per cambiare lo stato di una base di dati sono:
  - INSERT: inserimento di una nuova tupla in una relazione
  - DELETE: cancellazione di una tupla da una relazione
  - MODIFY: modifica di un attributo di una tupla
- **Importante: queste operazioni non devono portare alla violazione di alcun vincolo di integrità!!**
- Garantire questa condizione può richiedere di **propagare automaticamente** gli aggiornamenti

Operazioni di aggiornamento su relazioni

- Se si verifica una violazione di vincoli di integrità, ci sono diverse possibili opzioni:
  - Opzione RESTRICT (NO ACTION, REJECT): impedire l'esecuzione dell'operazione che causa la violazione
  - Opzioni CASCADE, SET NULL, SET DEFAULT: avviare altri aggiornamenti per eliminare la violazione
  - Eseguire *routine* specifiche definite dall'utente
  - [Eseguire l'operazione informando l'utente della violazione dell'integrità]

Violazioni per operazione INSERT

- L'operazione INSERT può violare tutti i vincoli:
  - Vincoli di dominio:
    - Il valore di uno o più attributi della/e nuova/e tupla/e non appartiene al dominio specificato nel modello
  - Vincolo di chiave:
    - Inserimento di tupla/e in cui il valore della chiave già esiste
  - Integrità referenziale:
    - Valore della chiave esterna (*foreign key*) che fa riferimento a valori della chiave primaria della relazione referenziata che non esistono
  - Integrità dell'entità:
    - Il valore della chiave primaria della/e nuova/e tupla/e è NULL

Esempi di violazione dei vincoli

Enrolled

sid	cid	grade
53666	Carnatic101	C
53666	Reggae203	B
53650	Topology112	A
53666	History105	B

Students

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

- Inserimento tupla in STUDENTS <53666, Red, red@math,19, 3.1>
  - Vincolo di chiave
- Inserimento tupla in STUDENTS <53666, Red, red@math,19, A>
  - Vincolo di dominio
- Inserimento in ENROLLED di nuova tupla <53501, Reggae03, 3.1>
  - Integrità referenziale
- Inserimento tupla in STUDENTS <NULL, Dantoni, dan@math, 18, 3.6>
  - Integrità entità

Violazioni per operazione DELETE

- L'operazione DELETE può eventualmente violare **solo** vincoli di integrità referenziale se vengono rimosse una o più tuple la cui chiave primaria è referenziata da altre tuple della relazione.

Enrolled

sid	cid	grade
53666	Carnatic101	C
53666	Reggae203	B
53650	Topology112	A
53666	History105	B

Students

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

- Cancellazione di <53666, Jones, jones@cs, 18, 3,4> in STUDENTS
  - Vincolo di integrità referenziale
- Cancellazione di <53666, Reggae03, A> in ENROLLED
  - No violazione

Violazioni per operazione UPDATE

- L'operazione di aggiornamento (UPDATE) può violare tutti i vincoli:
  - UPDATE della chiave primaria (PK):
    - Integrità referenziale
  - UPDATE di una chiave esterna (FK):
    - Integrità referenziale
  - UPDATE di un attributo ordinario (non PK né FK):
    - Vincoli di dominio o vincoli UNIQUE e NOT NULL

Esempi di violazione dei vincoli

Enrolled

sid	cid	grade
53666	Carnatic101	C
53666	Reggae203	B
53650	Topology112	A
53666	History105	B

Students

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

- Aggiornamento in STUDENTS: da <53666, Red, red@math,19, 3.1> a <53777, Red, red@math,19, 3.1>
  - Vincolo di integrità referenziale
- Aggiornamento in ENROLLED: da <53666, Reggae03, A> a <535011, Reggae03, A>
  - Vincolo di integrità referenziale
- Aggiornamento in STUDENTS: da <53666, Red, red@math,19, 3.1> a <53777, Red, red@math, A, 3.1>
  - Vincolo di dominio

Come preservare l'integrità referenziale

- RESTRICT (NO ACTION): rifiutare l'operazione
- CASCADE: cancellare tutte le tuple che referenziavano la chiave primaria della tupla cancellata o modificata
- SET NULL: assegnare il valore NULL alla chiave esterna delle tuple che referenziavano la chiave primaria della tupla cancellata o modificata
- SET DEFAULT: assegnare un valore di default alle chiavi esterne che referenziavano la chiave primaria della tupla cancellata o modificata

Come preservare l'integrità referenziale

NB: le opzioni SET NULL e SET DEFAULT **non sono disponibili** se la chiave esterna include attributi che sono anche chiave primaria della tabella referenziante

Enrolled

sid	cid	grade
53666	Carnatic101	C
53666	Reggae203	B
53650	Topology112	A
53666	History105	B

Students

sid	name	login	age	gpa
53666	Jones	jones@cs	18	3.4
53688	Smith	smith@eecs	18	3.2
53650	Smith	smith@math	19	3.8

La chiave primaria della relazione ENROLLED contiene gli attributi *sid* e *cid* che sono anche chiavi esterne. Quindi se cancellassimo la tupla con *sid* 53666 da STUDENTS e fissassimo un default (o NULL) per la chiave esterna di ENROLLED, introdurremmo una violazione del vincolo di integrità della relazione

Specifiche delle opzioni in SQL (esempio)

```
CREATE TABLE Enrolled ( studid CHAR(20),
                        cid    CHAR(20),
                        grade  CHAR(10),
                        PRIMARY KEY (studid, cid),
                        FOREIGN KEY (studid) REFERENCES Students
                                ON DELETE CASCADE
                                ON UPDATE NO ACTION )
```

- Propagazione della cancellazione quando si viola un vincolo di integrità referenziale
- Impedire un UPDATE se viola un qualsiasi vincolo